

LOGISTIC REGRESSION - EXPLAINED


Logistic Regression là gì?

Hồi quy logistic là một thuật toán phân loại. Bạn có thể dùng nó để phân loại các đối tượng:



Thay vì cố gắng dự đoán một con số (ví dụ: tôi nên bán ngôi nhà với giá bao nhiêu?), bạn đang cố gắng phân loại một thứ gì đó (này, đây có phải là một quả bưởi không?).


Tóm lại, hồi quy tuyến tính rất đơn giản: bạn lấy dữ liệu của mình và vẽ nó lên một biểu đồ. Sau đó bạn vẽ một đường thẳng sao cho nó khớp với dữ liệu tương đối tốt. Giờ bạn có thể dùng đường thẳng đó để dự đoán. Ví dụ, bạn có thể dùng đường này để dự đoán giá nhà dựa trên diện tích.



Đường thẳng tốt nhất là đường làm giảm chi phí (cost) xuống mức thấp nhất. Với hồi quy tuyến tính, chi phí là khoảng cách từ mỗi điểm dữ liệu đến đường thẳng.


Tương tự, khi bạn cố gắng phân loại một thứ gì đó, đầu tiên bạn sẽ vẽ dữ liệu của mình lên một biểu đồ.

Giả sử bạn đang cố gắng phân loại một loại trái cây mới là cam hay bưởi. Dưới đây là dữ liệu hiện có của bạn:



Tức là: bất kỳ thứ gì có đường kính nhỏ hơn 4 inch thì là cam, còn lớn hơn thì là bưởi.

Bây giờ bạn có thể vẽ một đường phân chia trên hình này. Bất kỳ điểm nào nằm bên trái đường này là cam, và bất kỳ điểm nào nằm bên phải đường này là bưởi:



Đây là cách hồi quy logistic hoạt động. Bạn vẽ dữ liệu của mình lên biểu đồ, sau đó vẽ một đường phân chia. Đường này được gọi là ranh giới quyết định (decision boundary), và nó chia dữ liệu thành các lớp khác nhau (trong trường hợp này là cam và bưởi).

Cũng giống như hồi quy tuyến tính, hồi quy logistic cũng cố gắng tìm ra một đường thẳng – nhưng trong trường hợp này, đó là ranh giới quyết định.

Prediction function

Với ví dụ về hồi quy tuyến tính, dữ liệu của chúng ta trông như thế này:

X	y
1000	\$200k
2000	\$250k
4000	\$300k

Tức là: diện tích nhà -> giá nhà.

Với ví dụ này, dữ liệu của chúng ta trông như thế này:

	X	y
FRUIT DIAMETER IN INCHES	1	Ø
	2	Ø
	3	Ø
	4	1
	5	1

Ø = NOT A GRAPEFRUIT
1 = GRAPEFRUIT

Tức là: đường kính trái cây -> có phải là bưởi hay không. Nếu là bưởi, thì $y = 1$. Ngược lại, $y = 0$.

Trong ví dụ hồi quy tuyến tính, ta dự đoán một con số (ví dụ: một ngôi nhà 3000 feet vuông sẽ bán được với giá \$270.000. Còn với hồi quy logistic, ta dự đoán một xác suất, chẳng hạn như “có 90% khả năng đây là một quả bưởi”.

Trong hồi quy tuyến tính, công thức dự đoán có dạng sau:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Bạn sẽ tính các giá trị cho θ_0 và θ_1 , sau đó sử dụng chúng để đưa ra dự đoán.

Ví dụ, nếu bạn muốn biết nên bán một ngôi nhà rộng 3000 feet vuông với giá bao nhiêu:

OPTIMAL VALUES
FOR θ_0 AND θ_1

↓ ↓

$$h_{\theta}(x) = 175,000 + 32.143 x$$

$$h_{\theta}(3000) = 271,430$$

Khi bạn đã có các giá trị tối ưu cho θ_0 và θ_1 , việc dự đoán trở nên đơn giản.

Chúng ta sử dụng gần như cùng một công thức cho hồi quy logistic, chỉ với một thay đổi:

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x)$$

↑
SIGMOID
FUNCTION

Hãy nhớ rằng, hàm dự đoán trong hồi quy logistic trả về một giá trị phần trăm. Ví dụ: “chúng tôi chắc chắn 95% rằng đây là một quả bưởi”. Hàm $g(\dots)$ được gọi là hàm sigmoid. Chính hàm này khiến hàm dự đoán trả về một giá trị trong khoảng từ 0 đến 1, tương ứng với phần trăm xác suất.

Kết quả 0.95 có nghĩa là chúng ta tin chắc 95% về điều gì đó. Đó là tất cả những gì bạn cần biết về hàm sigmoid.

Hàm sigmoid có dạng:

$$g(z) = \frac{1}{1 - e^{-z}}$$

Cũng giống như hồi quy tuyến tính, chúng ta sẽ sử dụng một hàm chi phí (cost function) để tìm các giá trị tốt cho θ_0 và θ_1 .

Nhưng với ví dụ đầu tiên này, tôi đã biết sẵn hai giá trị phù hợp. Vậy nên, hãy thay chúng vào:

$$h_{\theta}(x) = g(-7 + 2x)$$

$\theta_0 = -7$ và $\theta_1 = 2$. Bây giờ chúng ta có thể sử dụng hàm này để dự đoán xem một loại trái cây có phải là bưởi hay không!

Dưới đây là kết quả dự đoán cho các loại trái cây có đường kính từ 1 đến 5 inch.

ACTUAL VALUE
1 = IS A GRAPEFRUIT


X	y	PREDICTED
1	0	0.6%
2	0	4.7%
3	0	26.9%
4	1	73.1%
5	1	95.2%

PERCENT CHANCE THAT THIS IS A GRAPEFRUIT

Bạn có thể tự thử bằng cách thay các con số vào WolframAlpha.



[https://www.wolframalpha.com/input/?i=sigmoid\(-7+%2B+2*2\)](https://www.wolframalpha.com/input/?i=sigmoid(-7+%2B+2*2))

Hãy nhớ rằng, giá trị phần trăm đó chính là mức độ tin cậy rằng trái cây này là một quả bưởi. Khá chính xác đấy! Đường thẳng sẽ trông như thế này:



Chuẩn xác luôn. Bất kỳ điểm nào nằm bên trái đường thẳng là cam, và bên phải là bưởi.

Hãy nhớ rằng, hàm sigmoid chuyển đổi giá trị đó thành xác suất. Càng về bên trái, xác suất trái cây là bưởi càng thấp. Vì vậy, hàm sigmoid giúp làm mượt kết quả - thay vì chỉ trả về “có” hoặc “không”, nó cho bạn biết mức độ tin cậy (xác suất).




Vậy bây giờ, sau khi đã thấy hàm dự đoán hoạt động thế nào, hãy xem cách tìm các giá trị tối ưu cho θ_0 và θ_1 .

Tóm lại, cho đến hiện tại, điều duy nhất chúng ta đã thay đổi là hàm dự đoán $h(x)$, bằng cách thêm hàm sigmoid. Mọi thứ khác vẫn giống như trong hồi quy tuyến tính.

Tiếp theo, chúng ta cần thay đổi hàm chi phí.

The cost function

Trong hồi quy tuyến tính, chúng ta tính toán chi phí của việc sử dụng một đường thẳng:



Chi phí được tính dựa trên mức độ sai lệch của đường thẳng so với các điểm dữ liệu.

Trong hồi quy logistic, chi phí cũng phụ thuộc vào mức độ sai lệch giữa dự đoán và dữ liệu thực tế. Tuy nhiên, vì chúng ta làm việc với xác suất (phần trăm), nên cách tính chi phí sẽ hơi khác một chút.


Ví dụ, nếu bạn nói “có 95% khả năng đây là một quả bưởi”, nhưng thực tế lại là cam, thì bạn sẽ bị phạt nặng (tức là chi phí sẽ cao). Nhưng nếu bạn nói có 55% khả năng đây là một quả bưởi” và thực tế là cam, thì mức phạt sẽ nhẹ hơn (tức là chi phí sẽ thấp hơn).

Vì vậy, chi phí trong hồi quy logistic được tính dựa trên mức độ sai lệch của xác suất dự đoán so với thực tế. Chúng ta tính nó theo thang logarit, như sau:

IF y IS 1...



IF y IS 0...



y là kết quả thực tế. Vì vậy, nếu $y = 1$ (tức là đúng là một quả bưởi) và bạn dự đoán là 1 (tức là 100% khả năng là bưởi), thì bạn không bị phạt. Nhưng nếu bạn dự đoán là 0 (0% khả năng là bưởi), thì bạn sẽ bị phạt nặng.

Dự đoán càng sai, mức phạt càng lớn. Chúng ta sử dụng hàm log để phản ánh điều này.

Hàm chi phí trong hồi quy tuyến tính là:

FOR A GIVEN
THETA 0 AND THETA 1...

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$

4. FIND THE
AVERAGE

2. FIND THE DIFFERENCE
BETWEEN THE PREDICTED
AND ACTUAL VALUES

1. THE PREDICTED
VALUE

3. FIND ALL THE DIFFERENCES
BETWEEN PREDICTED AND ACTUAL

Hàm chi phí trong hồi quy logistic là:

$$-\frac{1}{m} \sum_{i=1}^m \begin{cases} -\log(h_{\theta}(x_i)) & \text{if } y_i = 1 \\ -\log(1 - h_{\theta}(x_i)) & \text{if } y_i = 0 \end{cases}$$

Và có một cách viết khéo léo để biểu diễn điều đó trên 1 dòng, như sau:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y_i \cdot \log(h_{\theta}(x_i)) + (1 - y_i) \cdot \log(1 - h_{\theta}(x_i))$$

Điều này hoạt động vì một trong 2 biểu thức đó sẽ luôn bằng 0, nên chỉ biểu thức còn lại được sử dụng – giống như trong câu lệnh if. Cá nhân tôi thích cách dùng câu lệnh if hơn, nhưng các video lại sử dụng cách viết gọn một dòng, nên tôi đưa nó vào đây.

Dưới đây là cách viết trong Octave:

```
function distance = cost(theta_0, theta_1, x, y)
distance = 0;
for i = 1:length(x) % arrays in octave are indexed starting at 1
    % you calculate the cost differently based on whether the actual value is 1 or 0.
    if (y(i) == 1)
        distance += -log(h(x(i), theta_0, theta_1));
    else
        distance += -log(1 - h(x(i), theta_0, theta_1));
    end
end
% get how far off we were on average
distance = distance / length(x);
```

end

Tóm lại:

- Chúng ta đã thêm hàm sigmoid vào hàm dự đoán, để nó trả về xác suất (phần trăm).
- Chúng ta đã thay đổi hàm chi phí (sử dụng hàm log thay vì hiệu giữa dự đoán và giá trị thực tế).

Vậy là xong! Chỉ 2 điểm đó là khác biệt, còn lại mọi thứ vẫn giữ nguyên. Chúng ta vẫn dùng gradient descent để lặp và tìm giá trị đúng cho các tham số θ_0 (và ngay cả công thức gradient descent cũng không thay đổi).

Dưới đây là ví dụ đầy đủ trong Octave.

<https://gist.github.com/egonSchiele/54abdc69ad843731eb77>

Bây giờ bạn đã biết cách xây dựng một bộ phân loại logistic regression rồi!



Multi-class classification


Bây giờ bạn đã hiểu cách hồi quy logistic hoạt động. Phần còn lại của bài viết này là tùy chọn, và sẽ đề cập đến một số vấn đề bạn có thể gặp phải khi áp dụng hồi quy logistic trong thực tế.

Làm thế nào để sử dụng hồi quy logistic để phân loại nhiều loại trái cây khác nhau, chứ không chỉ 2 loại?



(O = cam, G = bưởi, A = táo)

Khi đó, bạn sẽ cần nhiều ranh giới quyết định (decision boundaries):



Thực ra có một cách rất đơn giản để làm điều này, gọi là phân loại một-chống-tất cả (one-vs-all)! Ý tưởng như sau:

Đầu tiên, chỉ tập trung vào bưởi:



Vậy tức là trái cây là bưởi hoặc không phải bưởi (tạm thời gộp cam và táo vào cùng một nhóm). Bạn thực hiện phân loại và nhận được một con số, giả sử là 25%. Điều đó có nghĩa là có 25% khả năng đây là bưởi, và 75% khả năng không phải là bưởi.

Tiếp theo, bạn làm tương tự với cam:



Vậy tức là: hoặc đó là cam, hoặc không phải (gộp bưởi và táo vào một nhóm). Kết quả đầu ra là 75%.

Cuối cùng, làm tương tự cho táo:



Và bạn nhận được: 30%.

Vậy là có 25% khả năng đây là bưởi, 75% khả năng là cam, và 30% khả năng là táo.

Kết luận: đây là cam (vì có xác suất cao nhất)!

Non-linear classification

Giả sử tập dữ liệu của bạn trông như thế này:



Không có đường thẳng nào có thể dùng làm ranh giới quyết định trong trường hợp này. Bạn cần một ranh giới phi tuyến, ví dụ như thế này:



Bạn có thể thực hiện điều này với hồi quy logistic theo cách sau.

<https://gist.github.com/egonSchiele/979922cfe7966033f209>

Nó sử dụng một công thức dự đoán hơi khác một chút:

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x + \theta_2 (x - \theta_3)^2)$$

Tuy nhiên, nhìn chung thì rất khó để thực hiện phân loại phi tuyến bằng hồi quy logistic. Hồi quy logistic không phù hợp với những trường hợp như thế này:



Đây chính là lúc các bộ phân loại phi tuyến phát huy tác dụng.

Mạng nơ-ron (neural networks) và máy vector hỗ trợ (SVMs) đều rất giỏi trong việc phân loại phi tuyến.



Recap

Hàm logistic trả về một giá trị dạng phần trăm (xác suất)

Hàm sigmoid được dùng để giới hạn đầu ra trong khoảng từ 0 đến 1

Chi phí được tính theo thang logarit: dự đoán càng sai thì bị phạt càng nặng

Ranh giới quyết định (decision boundary) là đường phân chia dữ liệu thành 2 lớp khác nhau

Nếu có nhiều lớp, hãy sử dụng phương pháp phân loại một-chống-tất cả (one-vs-all)

Nếu cần phân loại phi tuyến, hãy chọn mạng nơ-ron hoặc máy vector hỗ trợ (SVMs)

<https://www.adit.io/posts/2016-03-13-Logistic-Regression.html>